Элементы статистики для построения гипотез A/B-тестирования

Применение базовых
инструментов статистики для оценки гипотезы

Применение базовых инструментов
статистики для оценки гипотезы

Цель урока

Понять, как применять базовые элементы статистики к данным.

Применение базовых инструментов
статистики для оценки гипотезы

Задачи урока

- Вспомнить, что такое распределения и их виды
- Рассмотреть виды визуализации распределений
- Узнать про базовые статистики и их различия

Применение базовых инструментов
статистики для оценки гипотезы

Распределения

Дискретное

(конечное количество
возможных значений)

Распределение — закон,
определяющий вероятность
для каждого возможного значения.

X	0	1
P(X = x)	0,9	0,1

Непрерывное

(бесконечное количество
возможных значений)

Распределение — функция,
характеризующая вероятность
реализации тех или иных
значений случайной
переменной.

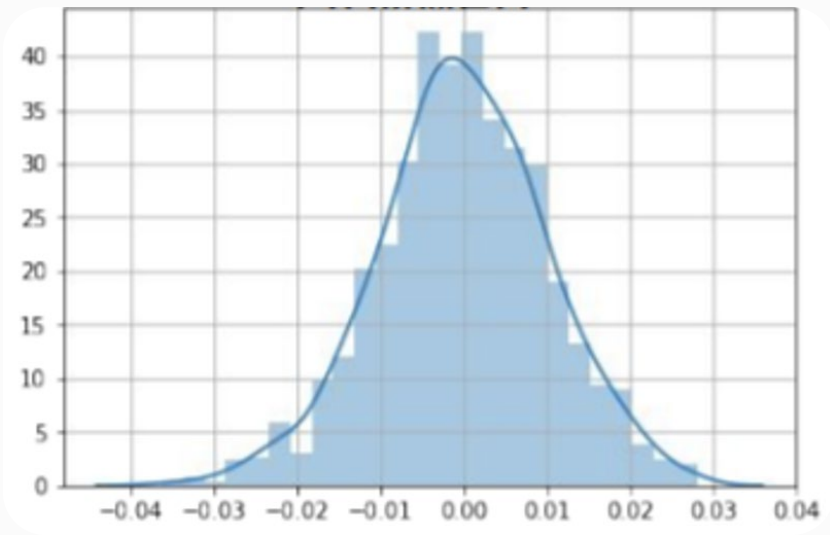

Применение базовых инструментов
статистики для оценки гипотезы

Визуализация распределений

Существует два популярных
и простых способа:

- Боксплот
- Гистограмма

Применение базовых инструментов
статистики для оценки гипотезы

Визуализация распределений

Существует два популярных
и простых способа:

- **Боксплот**
- **Гистограмма**

Сопоставление графика
плотности распределения
и ящика с усами

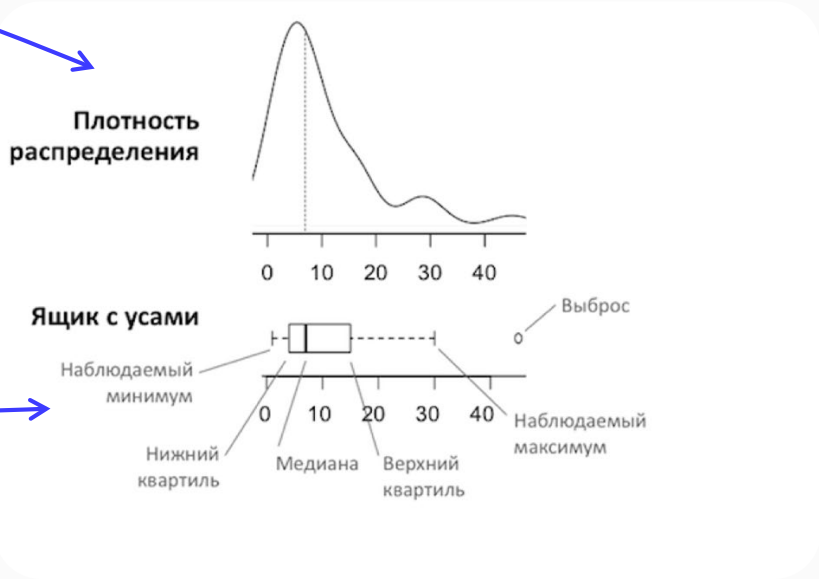

Применение базовых инструментов
статистики для оценки гипотезы

Гистограмма

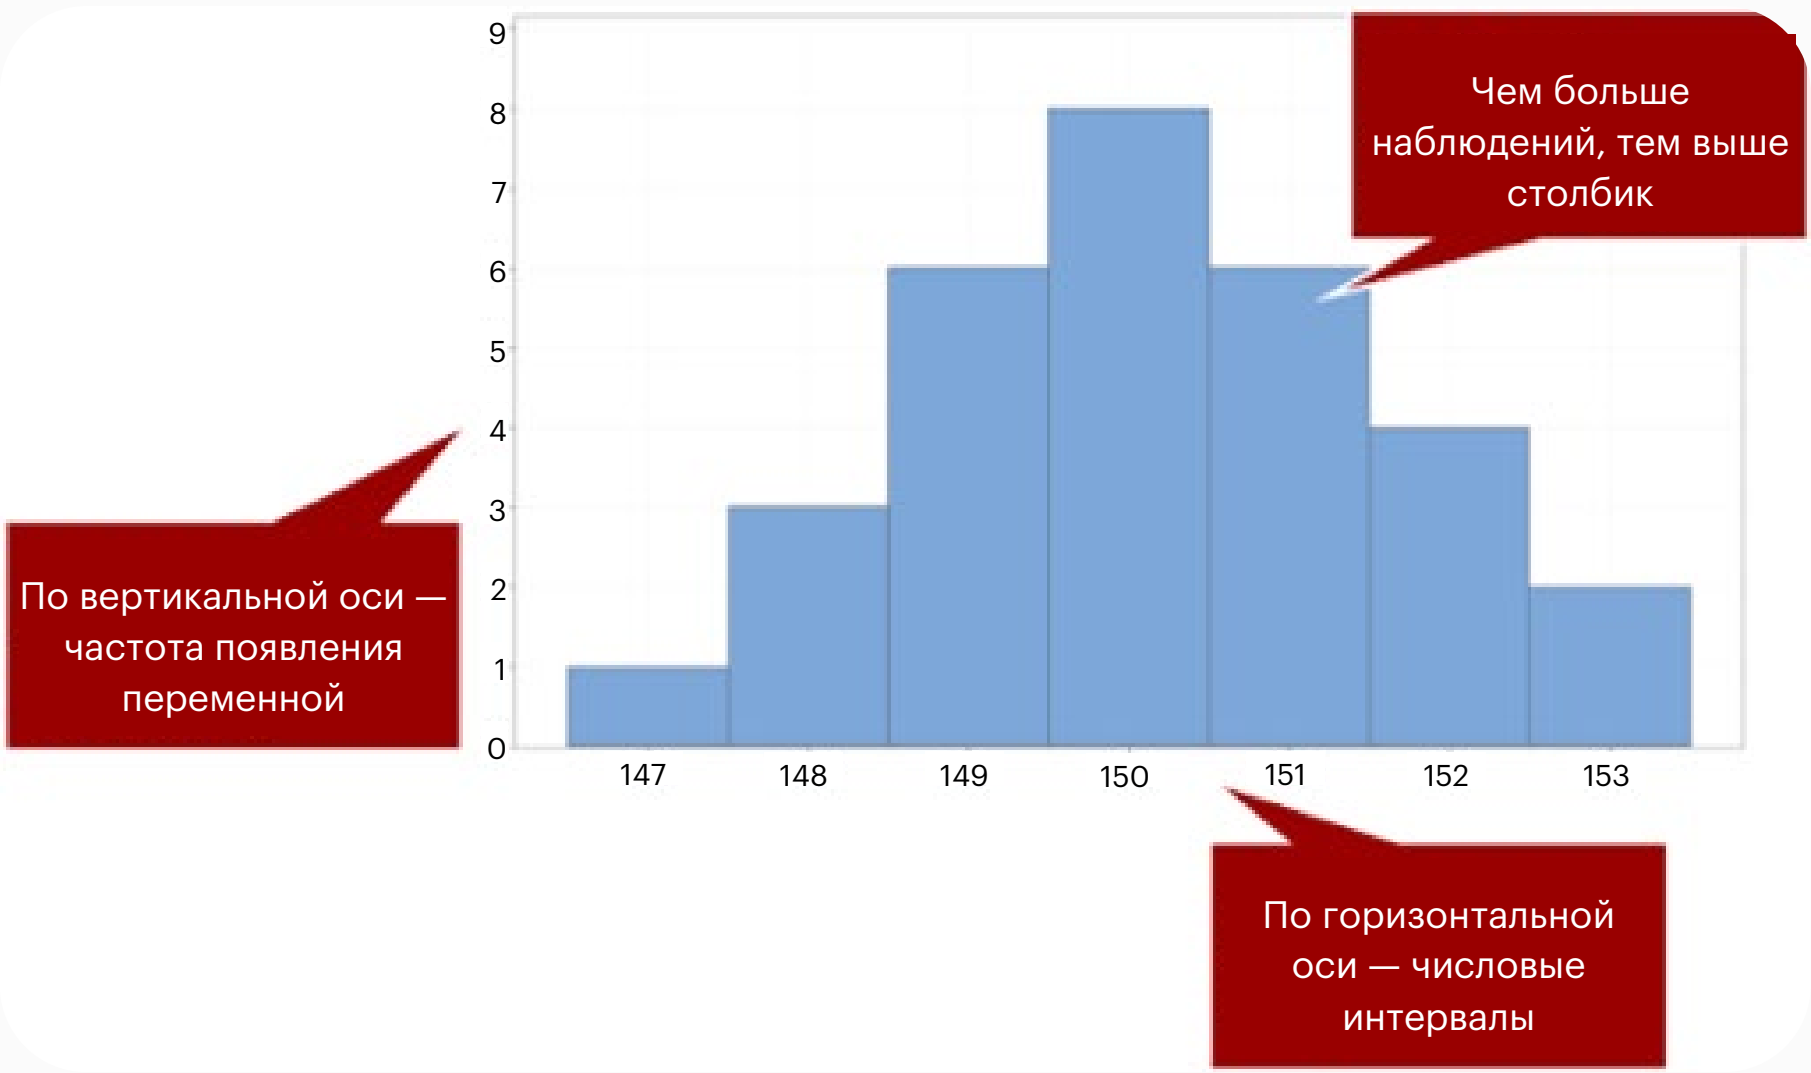

Применение базовых инструментов
статистики для оценки гипотезы

Теперь рассмотрим
пару важных статистик

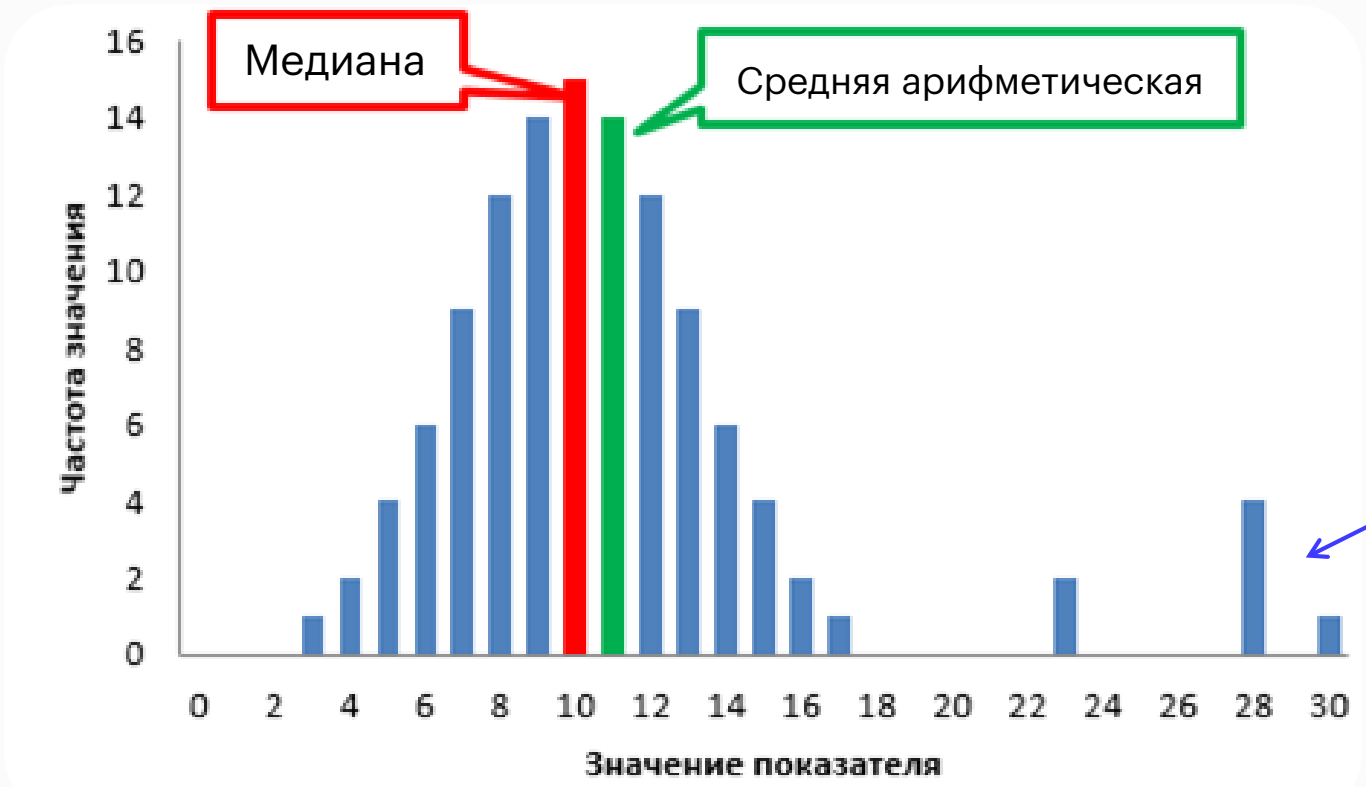

Медиана — это точка, слева и справа от которой лежит равное количество точек. Ключевая её особенность в том, что она слабо смещается из-за выбросов, в отличие от среднего.

Применение базовых инструментов
статистики для оценки гипотезы

Кейс: среднее или медиана?

- **Общий уровень зарплат в стране**

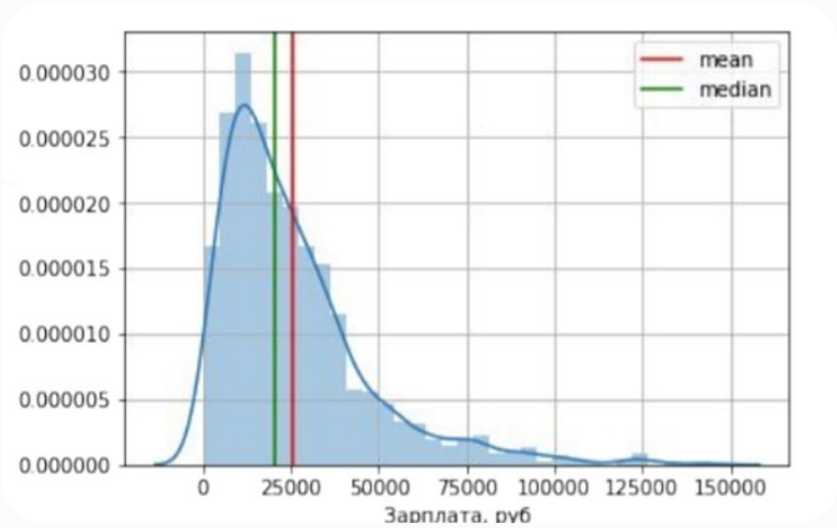

- **Ожидаемая температура в июне**

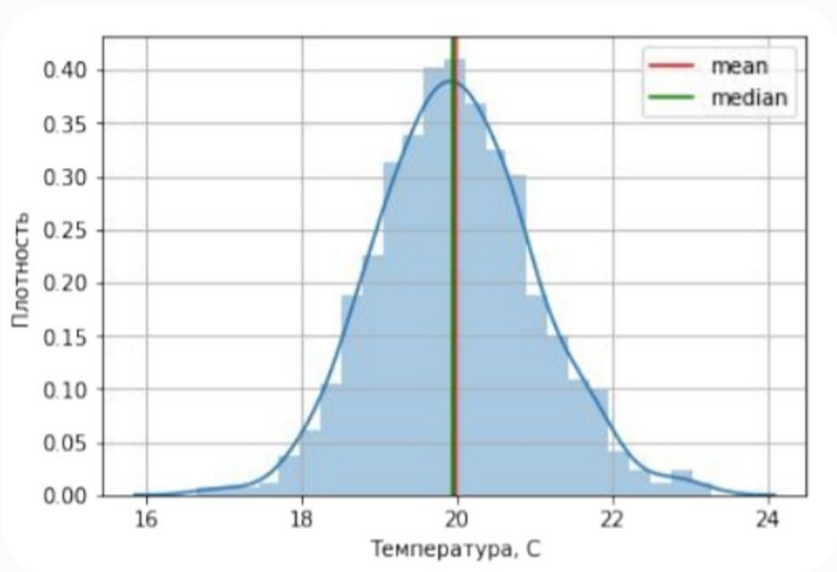

Применение базовых инструментов
статистики для оценки гипотезы

Кейс: среднее или медиана?

- **Общий уровень зарплат в стране**

  Ответ: медиана

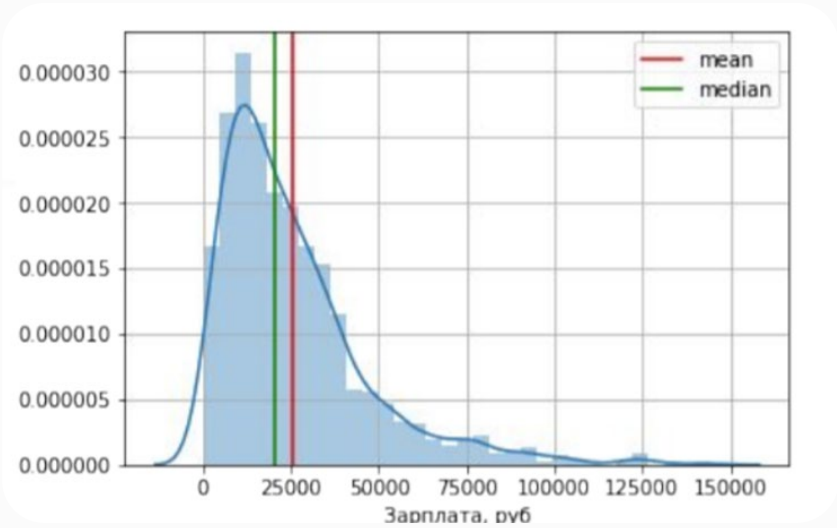

- **Ожидаемая температура в июне**

  Ответ: и то, и то

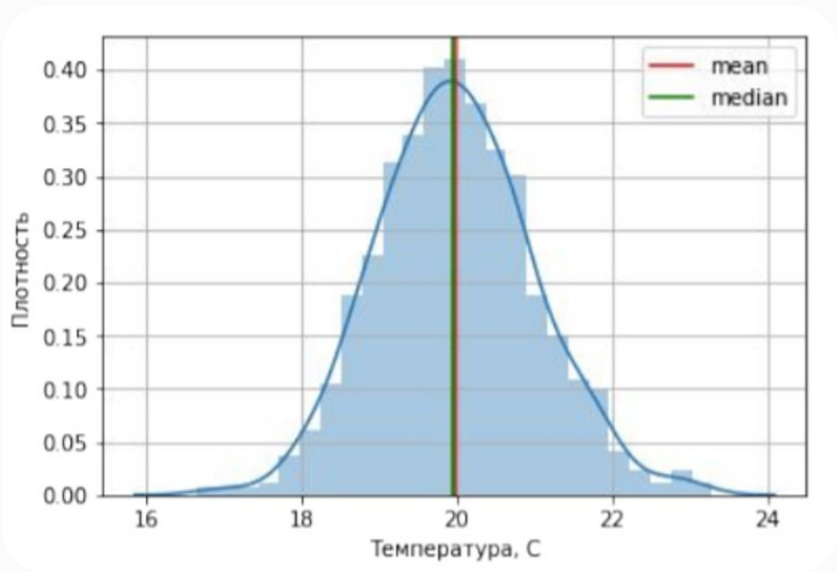

Применение базовых инструментов
статистики для оценки гипотезы

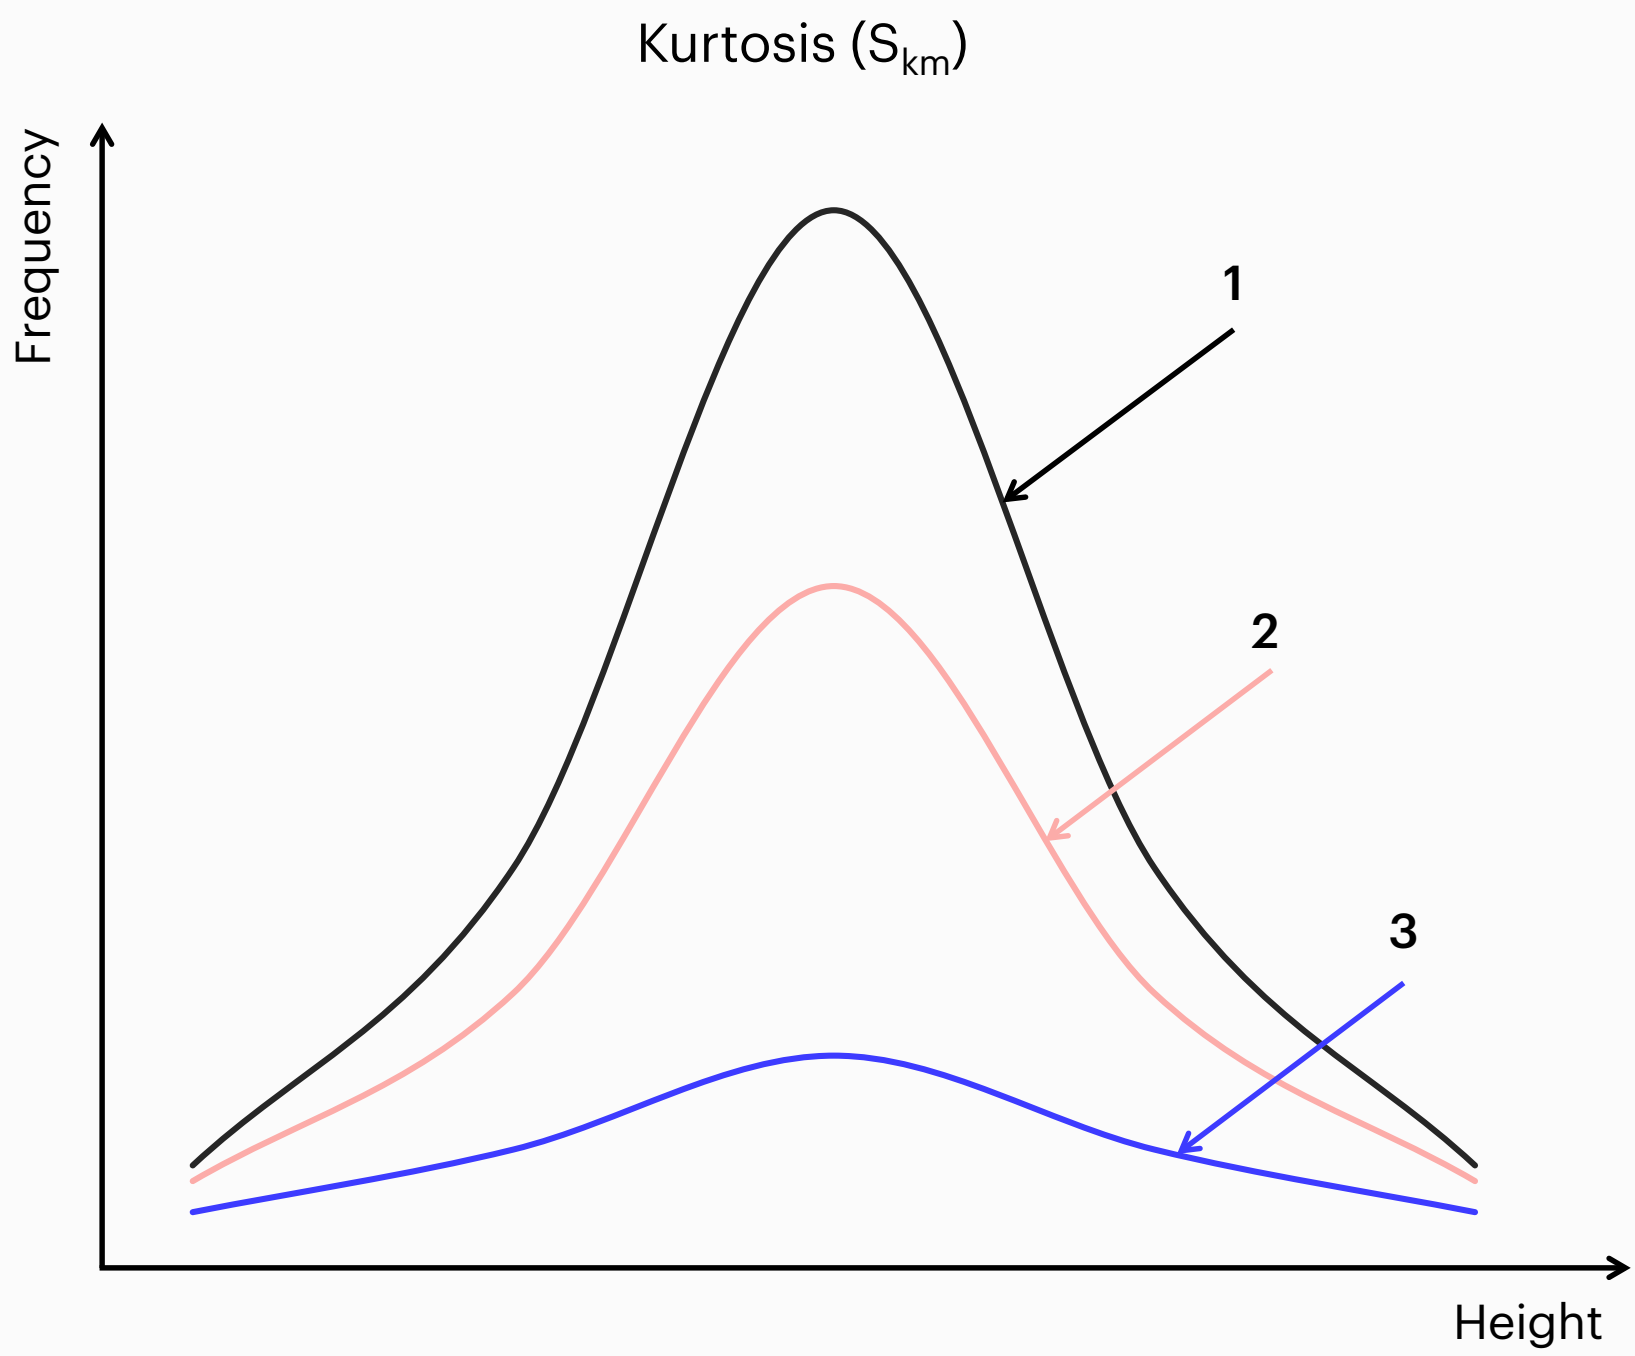

Применение базовых инструментов
статистики для оценки гипотезы

Важное понятие
для понимания боксплота — квантиль

Квантиль — значение, которое заданная случайная величина не превышает с фиксированной вероятностью.

Пример: 80 %-ный квантиль выхода из строя станков на заводе = 3 года.

Это значит, что 80 % станков выходят из строя в течение первых трёх лет, остальные 20 % станков работают больше 3 лет.

Применение базовых инструментов
статистики для оценки гипотезы

Важное понятие
для понимания боксплота — квантиль

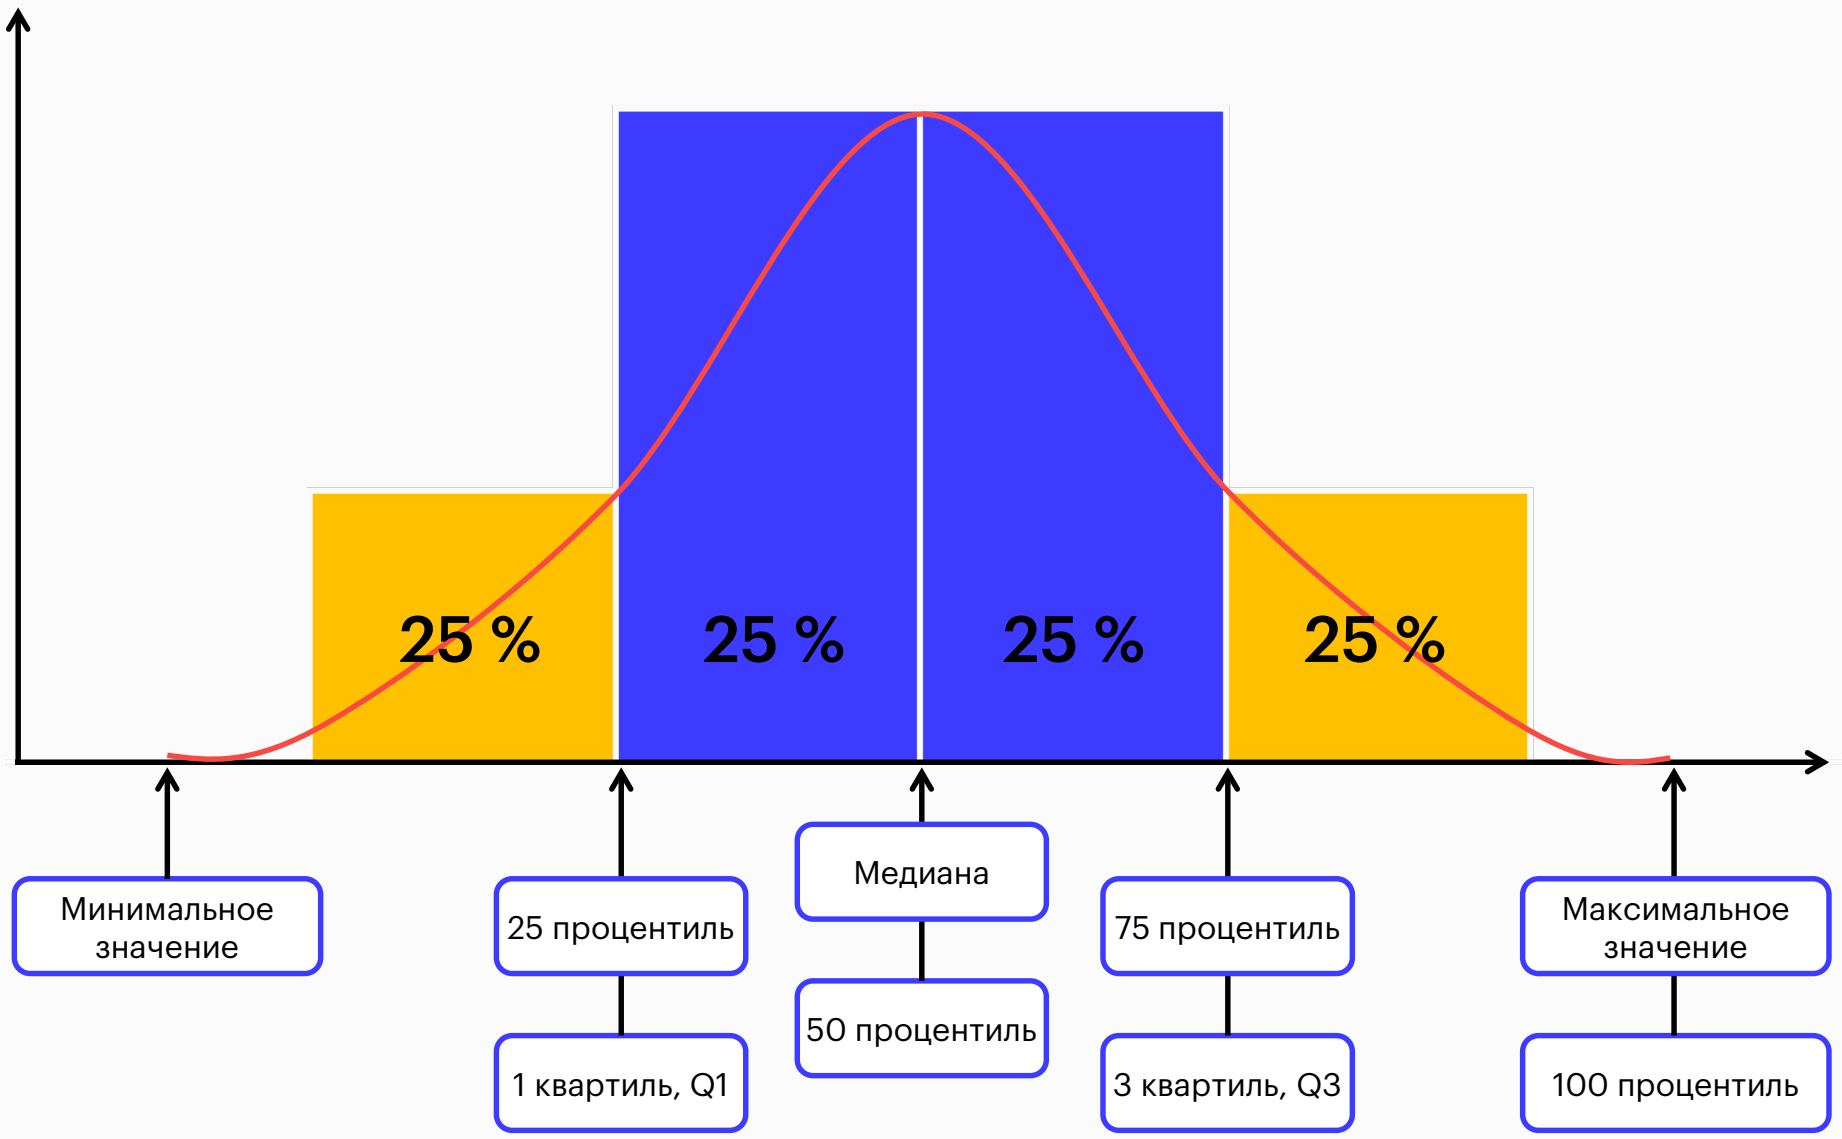

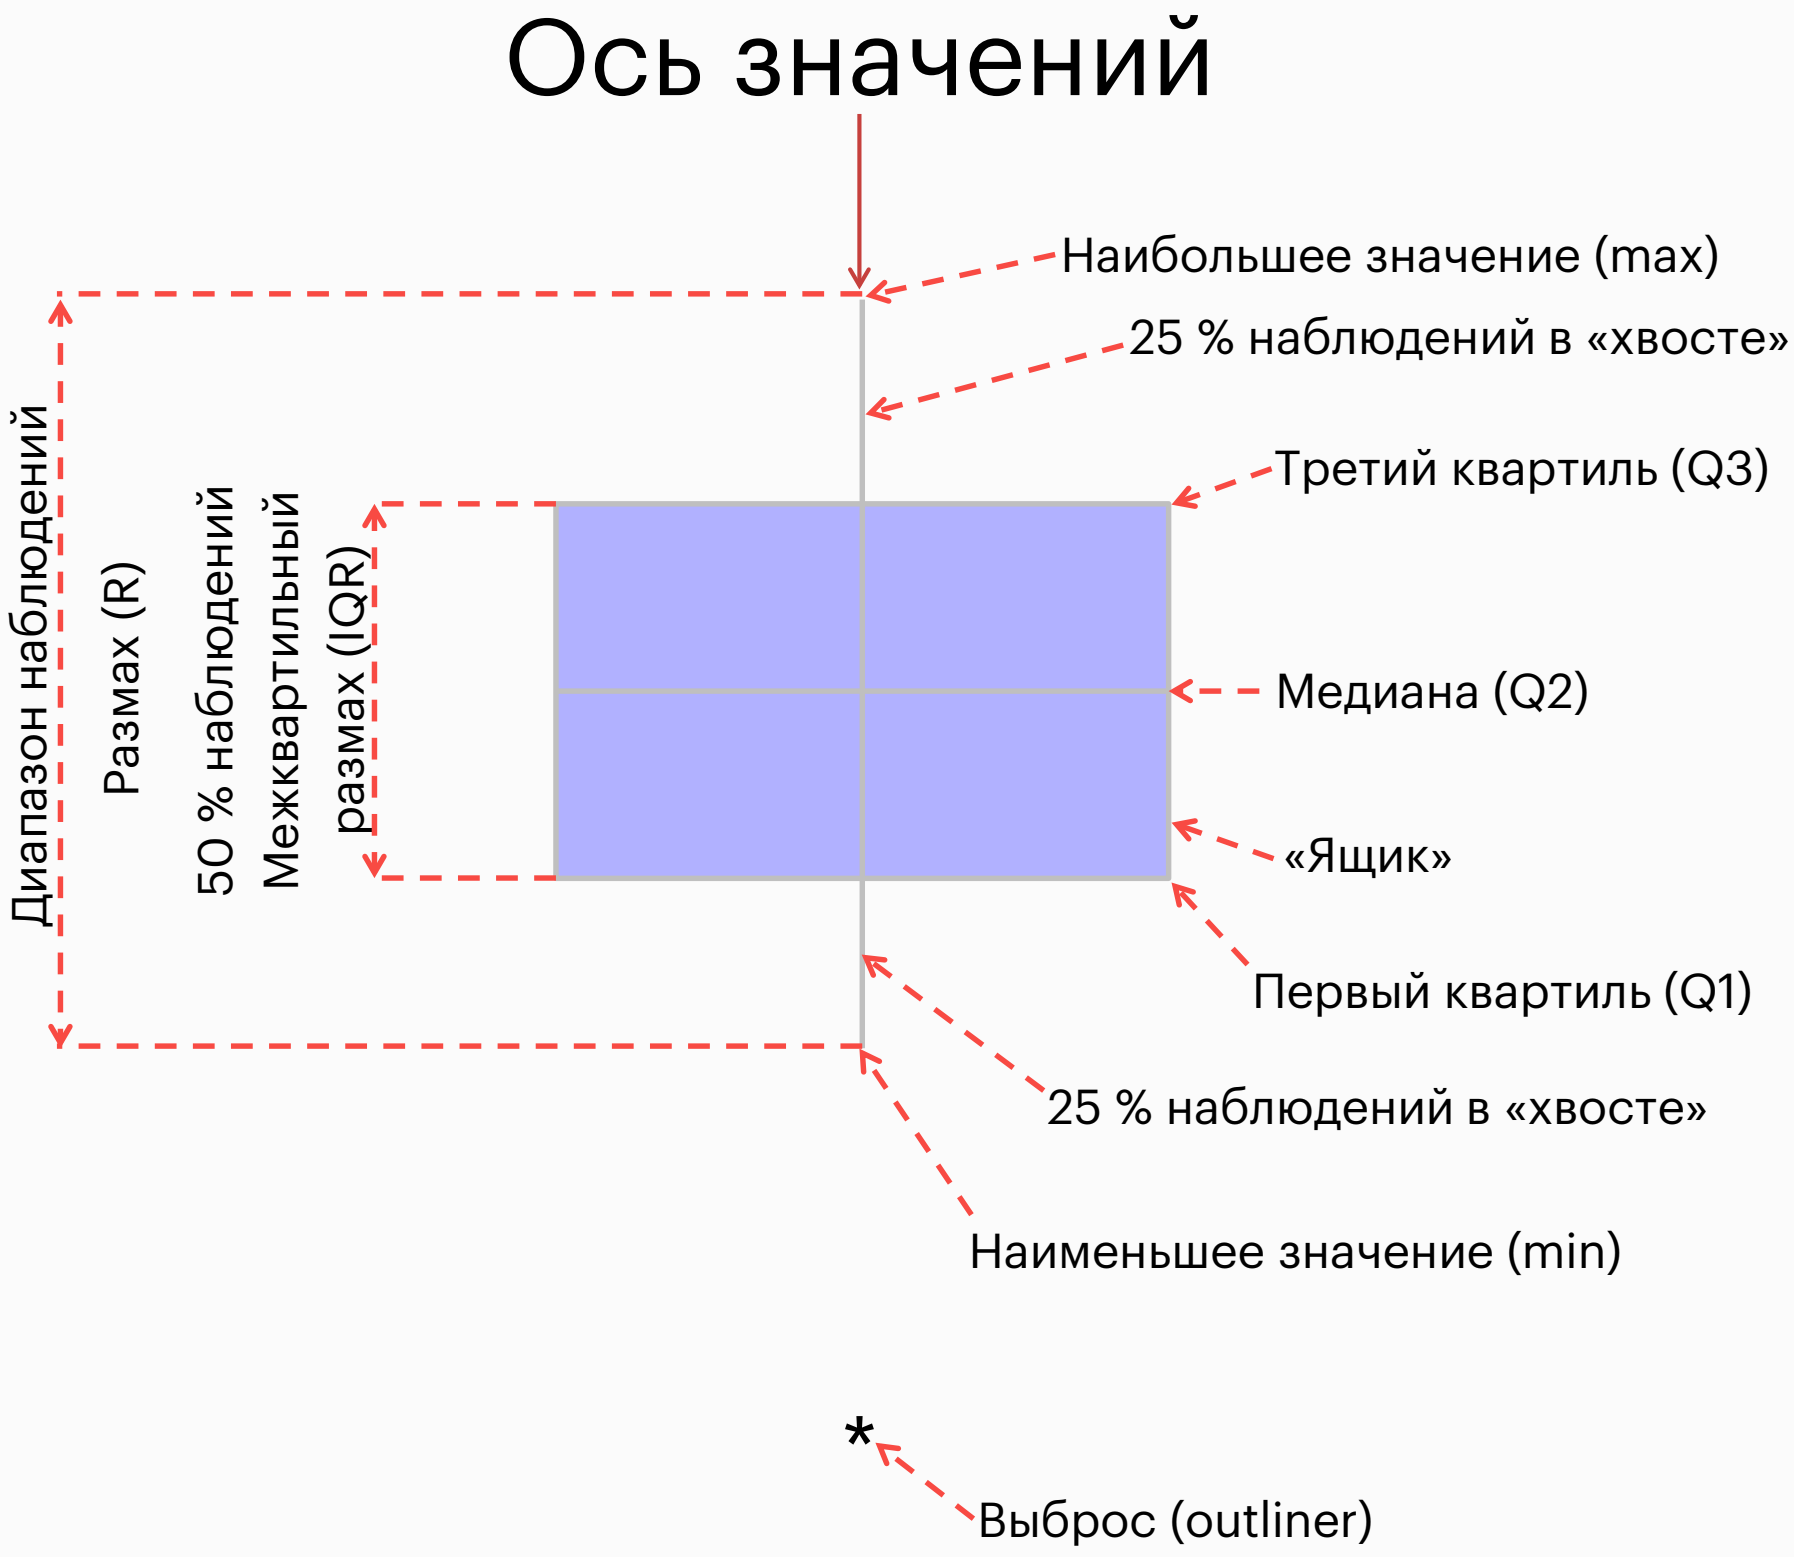
Ось значений
Наибольшее значение (max)
25 % наблюдений в «хвосте»
Третий квартиль (Q3)
Медиана (Q2)
«Ящик»
Первый квартиль (Q1)
25 % наблюдений в «хвосте»
Наименьшее значение (min)
Выброс (outliner)
Диапазон наблюдений
Размах (R)
50 % наблюдений
Межквартильный размах (IQR)

Применение базовых инструментов
статистики для оценки гипотезы

Боксплот («Ящик с усами»)

Зачем?

- Легко читаются основные статистики
- Чётко видно, где выбросы
- Хорошо оценивается степень асимметрии и разброса данных
- Бесценен, когда мало данных

Есть много видов боксплотов, поэтому необходимо уточнять, что чему соответствует.

Один из видов: когда «усы» — это минимум и максимум.

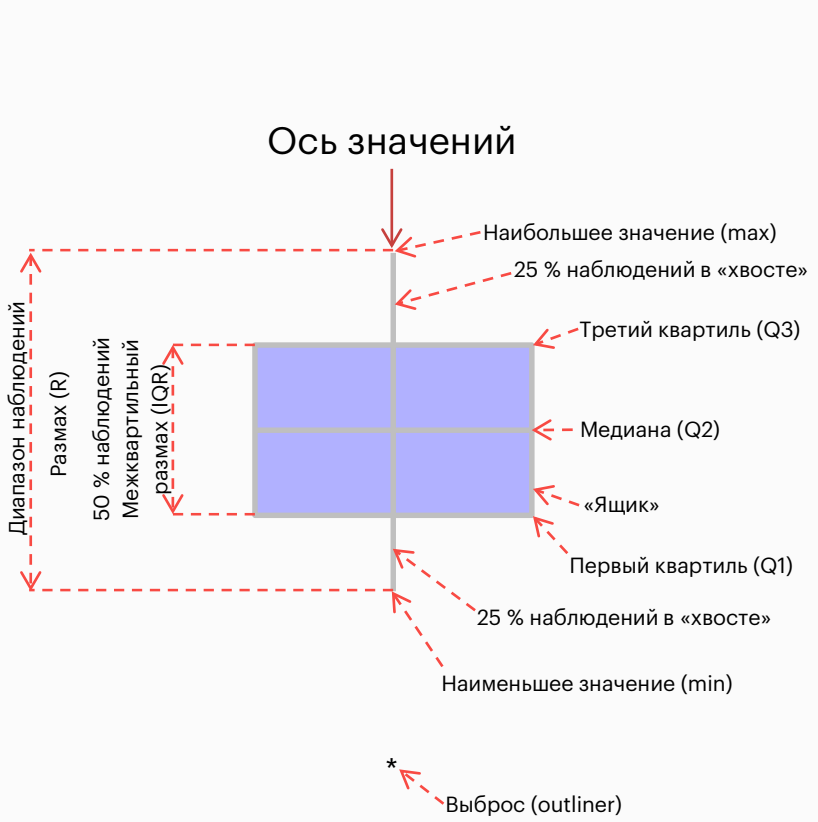

Зачем?

Оба способа визуализации хорошо помогают составить понимание о том, как выглядят ваши данные.

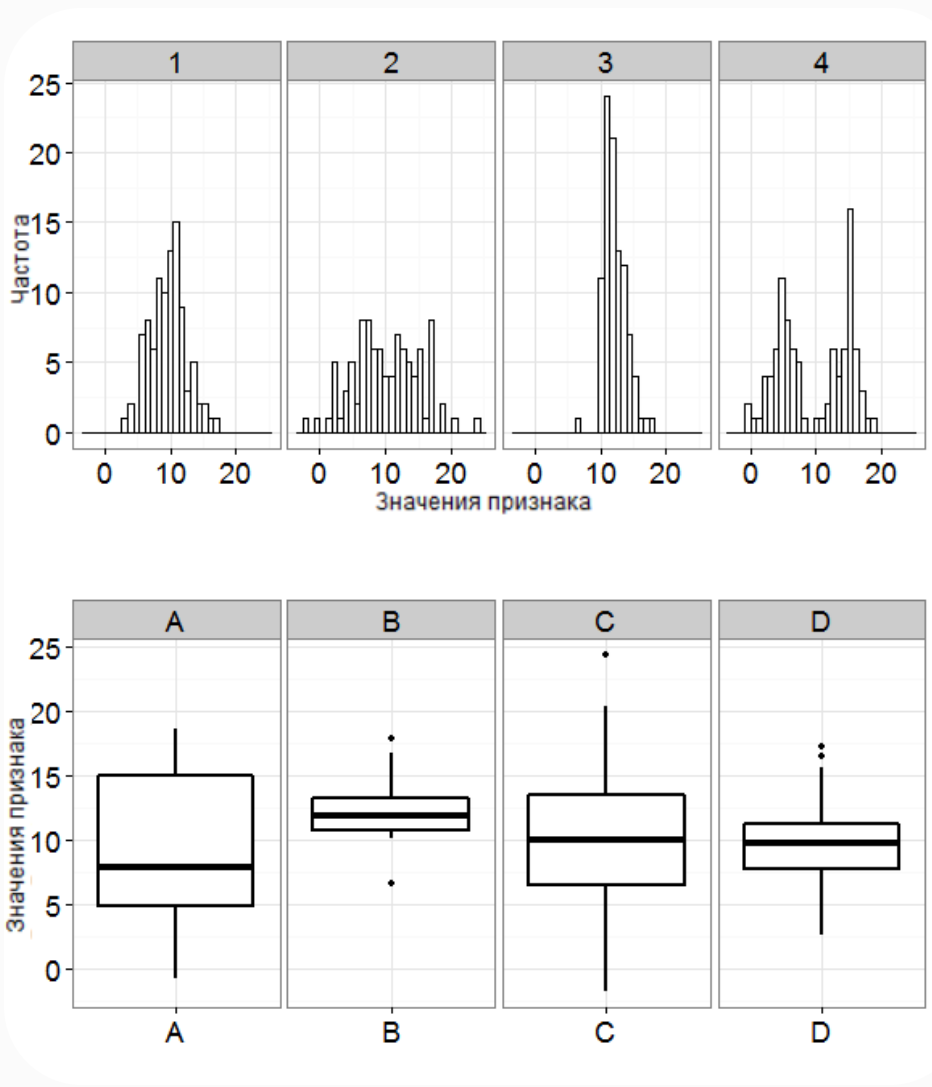

Применение базовых инструментов
статистики для оценки гипотезы

Самое популярное распределение — нормальное распределение

Основные свойства:

- медиана совпадает со средним
- с помощью окрестностей, кратных среднеквадратичному отклонению, можно выделить большое число наблюдений

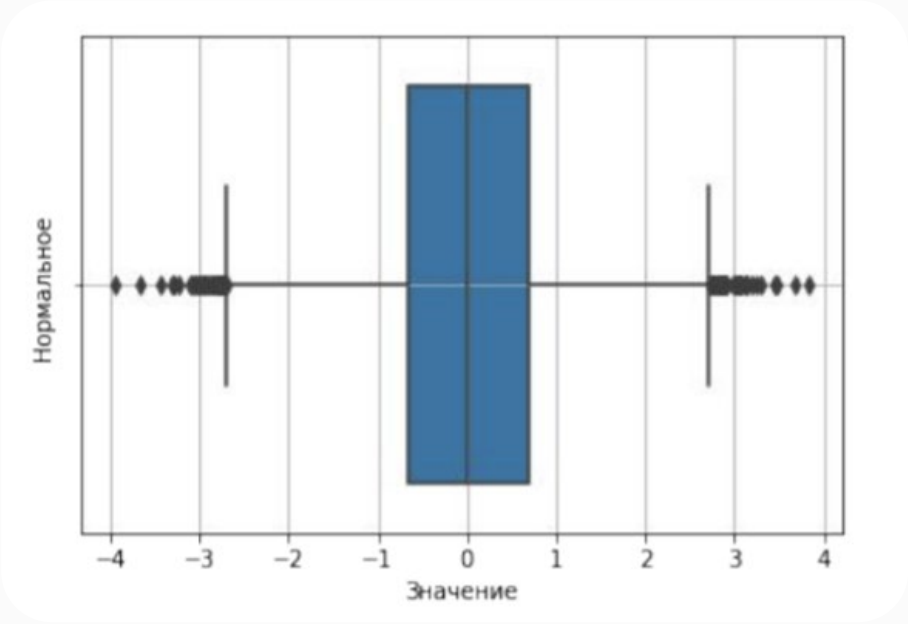

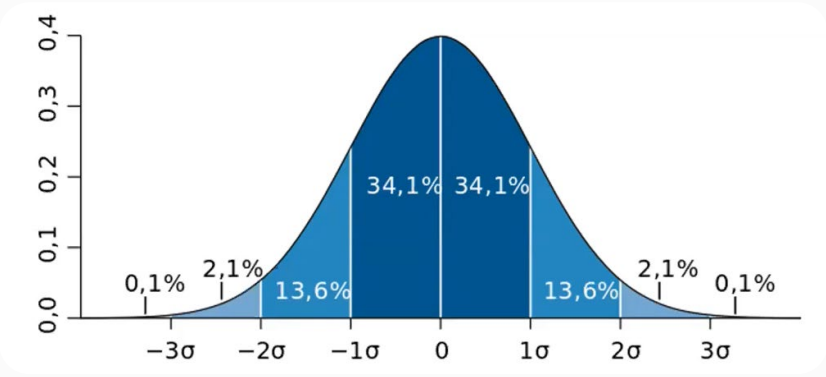

Применение базовых инструментов
статистики для оценки гипотезы

Самое популярное распределение — нормальное распределение

Пример: время, проведённое пользователями в приложении.

Гистограмма этого распределения выглядит примерно вот так:

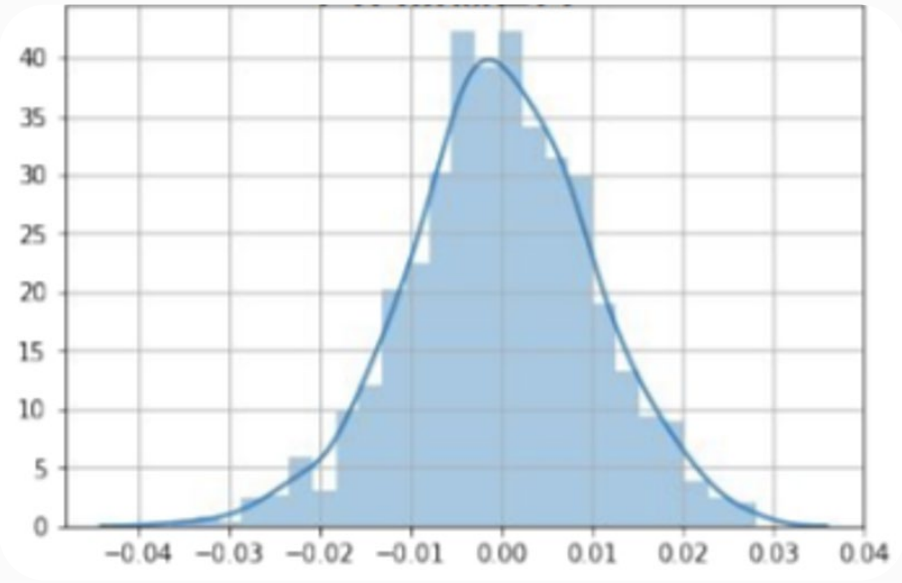

Применение базовых инструментов
статистики для оценки гипотезы

Виды распределений

На практике важно одно

У вас распределение нормальное или нет?
Какое именно распределение, уже не так важно.

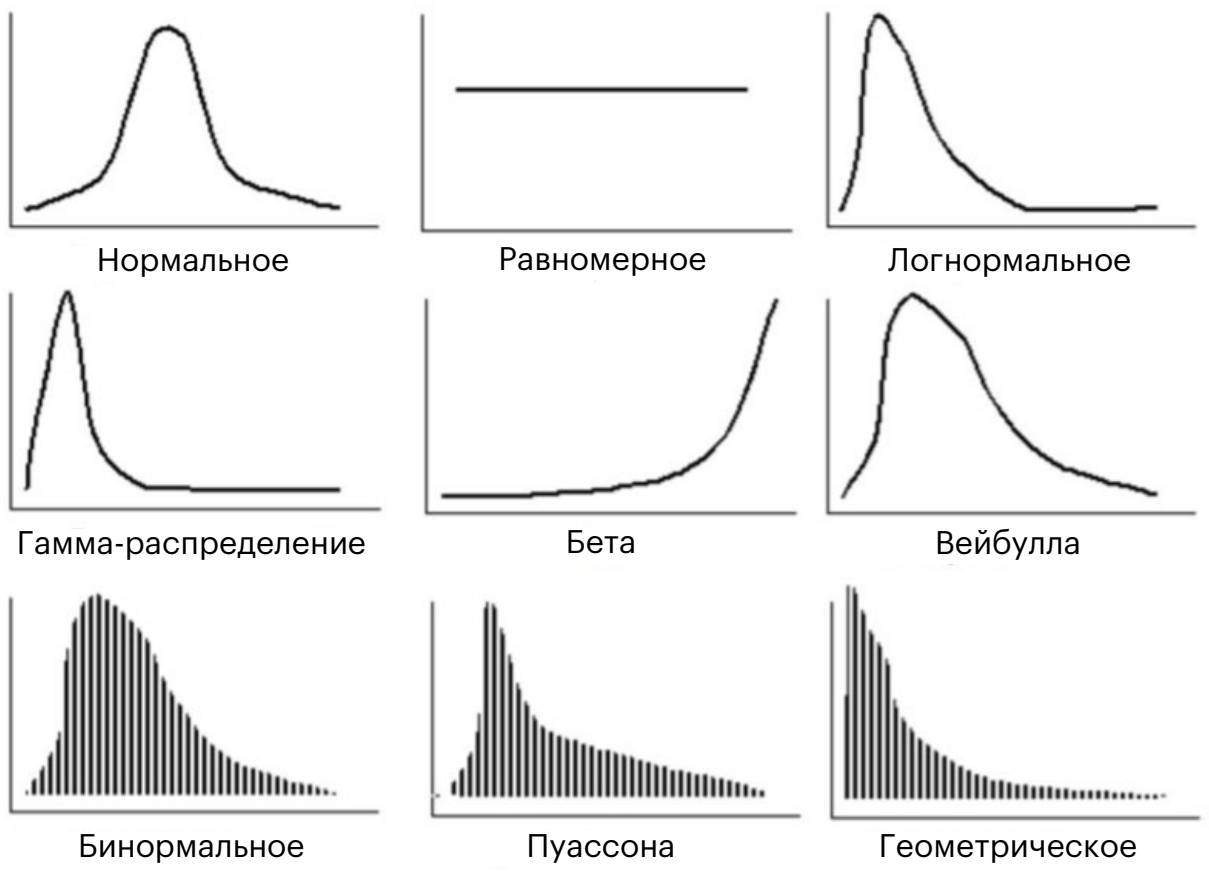

Применение базовых инструментов
статистики для оценки гипотезы

Теперь поговорим
про полезные теоремы статистики

Применение базовых инструментов
статистики для оценки гипотезы

Центральная предельная теорема (ЦПТ)

Проиллюстрируем примером:

1. Есть распределение, которое распределено ненормально
2. Берём выборки и считаем среднее в каждой
3. Строим распределение средних
4. Оно оказывается нормальным

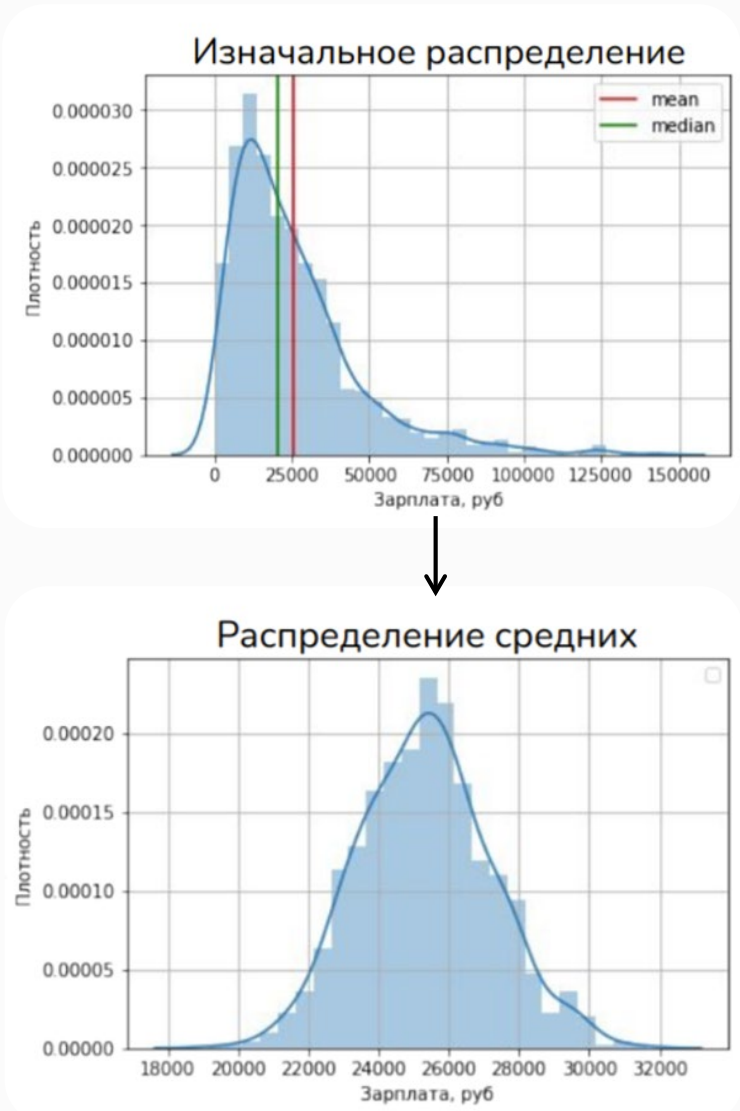

Применение базовых инструментов
статистики для оценки гипотезы

Центральная предельная теорема (ЦПТ)

Самое важное свойство — ЦПТ позволяет получить нормальное распределение из ненормального:

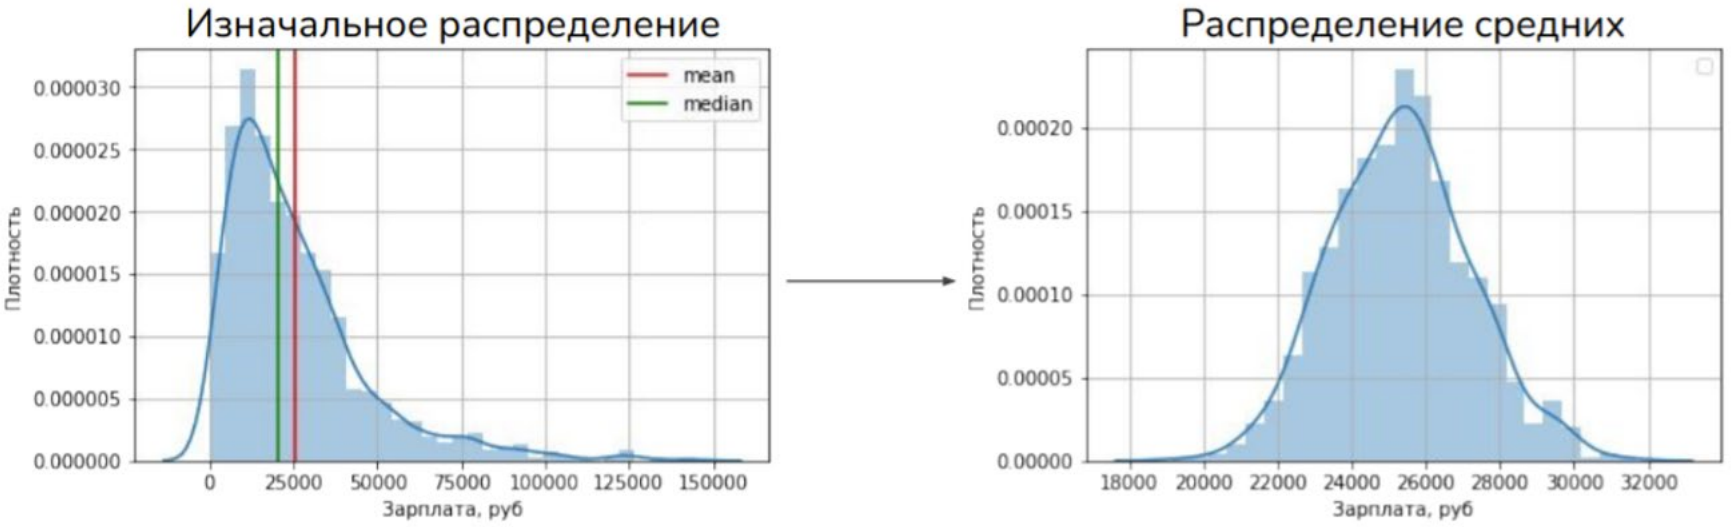

Применение базовых инструментов
статистики для оценки гипотезы

Причины
невыполнения ЦПТ

1 **Распределение имеет бесконечную дисперсию**

Можем наблюдать
её при «тяжёлых хвостах»

Так как часто мы не знаем
формулу распределения,
то любой из «хвостов» может
уйти в бесконечность

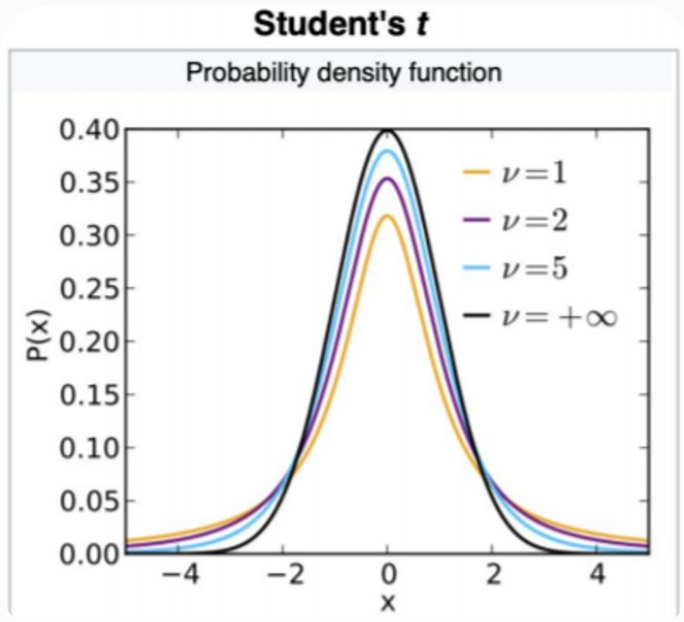

2 **Имеются выбросы в распределении**

Аномальные значения метрики

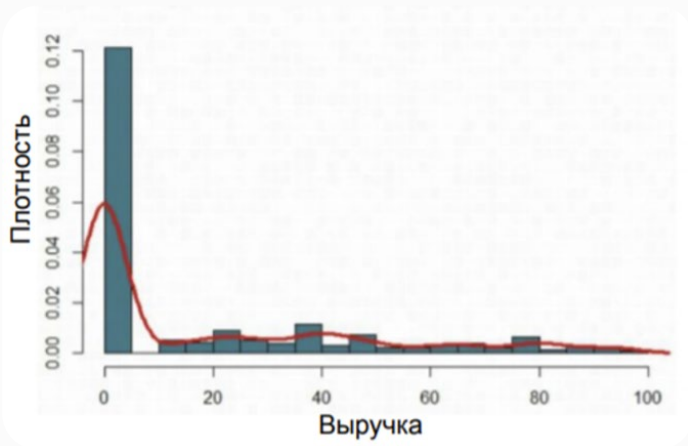

Применение базовых инструментов
статистики для оценки гипотезы

Итоги урока

- Распределение бывает дискретным и непрерывным
- Данные визуализируем гистограммой и боксплотом
- Самое удобное распределение данных — нормальное
- Самые популярные статистики — медиана, среднее и дисперсия